جزوه آمار و احتمال

نام استاد: جناب آقای دکتر یوسفی

دانشگاه آزاد - واحد تهران مرکز

نیم سال اول ۱۴۰۴

مقدمه

برای اینکه بتوان از روی مشاهدات قسمتی از جامعه یک نتیجه گیری و قضاوت منطقی داشته باشیم از نظریه احتمالات استفاده میکنیم.

یادآوری چند تعریف

آمار توصیفی: روش های تهیه و تنظیم و خلاصه کردن، طبقه بندی اطلاعات عددی و غیرعددی و نمایش آنها به صورت جدول و نمودارها.

آمار استنباطی: تجزیه، تحلیل و نتیجه گیری آماری.

جامعه(N): مجموعه تمام افراد یا اشیای مورد مطالعه آماری

نمونه(n): زیرمجموعه ای از جامعه که طبق یک قاعده و ضابطه ای برای مطالعه انتخاب میشوند

داده ها: صفت مورد مطالعه باید به صورت اعداد نمایش داده شود که به دو صورت گسسته و پیوسته هستند

نمودارهای آماری

نمودار میله ای: دو محور عمود بر هم. محور افقی x ها و محور عمودی فراوانی نسبی

نمودار دایره ای: دایره را به تعداد طبقه های جدول فراوانی تقسیم میکنیم و اندازه هر قطاع به اندازه فراوانی * ۳۶۰ درجه است.

هیستوگرام(نمودار ستونی): تعدادی مستطیل هایی به تعداد رده ها و ارتفاع آن به اندازه میزان فراوانی

منحنی فراوانی: اگر تعداد داده ها زیاد و طول رده ها کوچک باشند با منحنی میتوانیم نشان دهیم

اصول شمارش

اصل ضرب: یک کار را بتوان با دو یا چند عمل پیاپی انجام داد. مثلا عمل A را به m حالت و عمل B را به nحالت انجام شود. در نتیجه کل این کار با m*nحالت انجام میشود. مثال چند عدد ۲ رقمی با 0,1,2,3

اصل جمع: اگر یک کار را بتوان با دو عمل انجام داد ولی نتوانند همزمان انجام شوند آنگاه کل این کار به m+n حالت انجام میشود.

تبدیل: اگر از بین n عنصر متمایز بخواهیم r عنصر را انتخاب کنیم و **ترتیب مهم** است که تکرار مجاز نباشد $P(n,r) = \frac{n!}{(n-r)!}$ و اگر تکرار مجاز باشد n^r

مثال: از بین 10 کتاب، 3 کتاب را انتخاب کنیم و پشت سر هم روی میز بچینیم. هم انتخاب مهم است، هم ترتیب.

ترکیب: **ترتیب مهم نیست.** فقط انتخاب مهم است. مثال: از 10 نفر، 3 نفر را انتخاب کنیم. اینکه چه کسی اول یا آخر باشد فرقی ندارد $C(n,k) = \frac{n!}{k!(n-k)!}$

خلاصه کردن داده ها در چند عدد

با نمایش نمودار و جدول فراوانی داده ها تا حدودی درک بهتری از اطلاعات جامعه میرسیم. برای اینکه بتوانیم داده ها را در یک یا چند عدد خلاصه کنیم به معیار یا شاخص نیاز داریم:

شاخص های تمرکز:

- میانگین: $\bar{x} = (\frac{1}{n}) \sum_{i=1}^{n} x_i$
- سایر شاخص ها مثل: میانه، نما یا مد

شاخص های پراکندگی:

- واریانس: $Var(x) = (\frac{1}{n}) \Sigma (xi - \bar{x})^2$
- انحراف استاندارد: $SD_x = \sqrt{Var(x)}$
- سایر شاخص ها مانند: دامنه داده ها، میانگین انحرافات

کوواریانس: برای تعیین میزان همجهت بودن یا نبودن دو متغیر استفاده میشود

فرمول کوواریانس: $Cov(X, Y) = (\frac{1}{n}) \Sigma (x_i - \bar{x})(y_i - \bar{y})$

- Cov(X,Y) > 0 → وقتی X زیاد می‌شود، Y هم معمولاً زیاد می‌شود (هم‌جهت)
- Cov(X,Y) < 0 → وقتی X زیاد می‌شود، Y معمولاً کم می‌شود (خلاف‌جهت)
- Cov(X,Y) = 0 → رابطه‌ی خطی مشخصی ندارند

کوواریانس جهت تغییرات دو متغیر را نشان می‌دهد، اما **ضریب همبستگی** علاوه بر جهت، شدت رابطه خطی را نیز به‌صورت نرمال‌شده و مستقل از واحد بیان می‌کند.

فرمول محاسبه ضریب همبستگی خطی به صورت زیر است و عددی بین -۱ و ۱ است که نشان دهنده جهت و شدت همبستگی است:

$$p(x,y) = \frac{Cov(x,y)}{\sigma_x \sigma_y}$$

نکته: وقتی با جمعیت سر و کار داریم از N استفاده میکنیم و وقتی با نمونه کار میکنیم از n-1 استفاده میشود. اگر در سوالی به طور واضح از کلمه نمونه استفاده نشود منظور جمعیت است.

توابع توزیع

توزیع یکنواخت: همه چیز برابر و احتمال‌ها یکسان

توزیع نرمال: زنگوله‌ای، اطراف میانگین پرتراکم

برنولی: یک آزمایش با نتیجه‌ی ۰ یا ۱ فقط دو حالت دارد: موفقیت (۱) و شکست (۰)

- p = احتمال موفقیت
- 1 - P = احتمال شکست

توزیع دو جمله ای: وقتی n آزمایش برنولی انجام شود

- X تعداد موفقیت
- n-x تعداد شکست
- n تعداد آزمایش

p(x) = $comb(n,\ x)p^x(1\ -\ p)^{n-x}$

مثال‌ها:

- پرتاب سکه (شیر = ۱، خط = ۰)
- درست/نادرست بودن پاسخ
- خرید کردن/نکردن مشتری

نرمال سازی داده ها

گامی مهم برای شروع تحلیل و پیش بینی است. فرآیندی است که طی آن مقادیر عددی ویژگی های مختلف داده ها را به یک محدوده عددی مشترک(مثلا ۰ تا ۱) تبدیل میکنیم بدون آنکه توزیع اصلی داده ها تغییر کند.

چرا داده ها را نرمال میکنیم:

1. اثر مقیاس: وزن ویژگی‌های بزرگ‌تر در مدل بیشتر می‌شود در نتیجه الگوریتم‌ها به صورت ناعادلانه به یک ویژگی اهمیت می‌دهند
2. سرعت بخشیدن به همگرایی: سرعت در رسیدن به نقطه(جواب) بهینه. مثل گرادیان کاهشی
3. الگوریتم های وابسته به فاصله: عملکرد ضعیفی در اثر نرمال نبودن داده ها بوجود میآید. نرمال‌سازی باعث می‌شود همه ویژگی‌ها به یک اندازه در فاصله نقش داشته باشند.

انواع روش های نرمال سازی

- روش Min - Max: داده ها را در یک بازه مشخص نگه میدارد

$$X_{norm} = \frac{(X - X_{min})}{(X_{max} - X_{min})}$$

مزایا: ساده، قابل درک و خروجی در محدوده ثابتی است.

معایب: به شدت به داده ها پرت حساس است

- روش استاندارد سازی z-score: **به گونه ای انجام میشود که میانگین داده ها برابر صفر میشود و انحراف معیار برابر با ۱ میشود**. بنابراین بازه خروجی ثابت نیست و نسبت به انحراف معیار حساس نیست

$$X_{std} = \frac{(X - \mu)}{\sigma}$$

مزایا: در برابر داده های پرت مقاوم تر از روش min-max است

معایب: خروجی داده ها در یک محدوده ثابتی نیست

- نرمال سازی Robust Scaling
- نرمال سازی Max Abs

قانون اعداد بزرگ(Law of Large Numbers)

با افزایش تعداد دفعات تکرار یک آزمایش تصادفی، میانگین نتایج به‌دست‌آمده به میانگین واقعی جامعه نزدیک‌تر می‌شود و این همگرایی با افزایش تعداد نمونه‌ها قوی‌تر می‌شود.

قضیه حد مرکزی

اگر از هر جامعه‌ای (با هر توزیعی) نمونه‌های تصادفی به اندازه کافی بزرگ بگیریم و میانگین این نمونه‌ها را محاسبه کنیم، توزیع این میانگین‌ها به طور فزاینده‌ای به توزیع نرمال (گاوسی) نزدیک می‌شود، صرف‌نظر از شکل توزیع اولیه جامعه اصلی؛ این قضیه اهمیت حیاتی در استنباط آماری دارد و اجازه می‌دهد از ویژگی‌های توزیع نرمال برای تحلیل داده‌ها استفاده کنیم، حتی وقتی توزیع داده‌ها نرمال نیست.

امید ریاضی (Expected Value)

در آمار و احتمالات، میانگین تئوری یک متغیر تصادفی است که با ضرب هر مقدار ممکن در احتمال وقوع آن و جمع نتایج به‌دست می‌آید؛ به عبارت ساده‌تر، میانگین بلندمدت نتایج یک رویداد تصادفی است، که در بازی‌های شانسی، مقدار پولی است که انتظار دارید به طور متوسط برنده یا بازنده شوید.

مفهوم اصلی تعریف: مجموع حاصل‌ضرب هر نتیجه ممکن در احتمال وقوع آن نتیجه است (در مورد متغیرهای گسسته).مثال تاس: اگر یک تاس را بی‌نهایت بار پرتاب کنید، میانگین اعداد به‌دست آمده به

سمت ۳.۵ میل می‌کند (چون هر عدد (۱ تا ۶) با احتمال ۱/۶ رخ می‌دهد).کاربرد: برای پیش‌بینی نتایج بلندمدت در شرایط عدم قطعیت، مانند تحلیل بازی‌های شانسی، بیمه و مالی.

فرمول (برای متغیر تصادفی گسسته)

$$E(x) = \sum_{i=1}^{n} (x_i . p(x_i))$$

تابع توزیع پواسون

یک تابع توزیع گسسته است برای مدل سازی تعداد دفعات وقوع یک حادثه در یک بازه زمانی یا مکانی مشخص. میگوییم x دارای توریع پواسون با پارمتر ۸ است که ۸ نشان دهنده میانگین نرخ وقوع پیشامد در آن بازه است. تابع جرم احتمال توزیع پواسون یه صورت زیر محاسبه میشود:

میانگین و واریانس در توزیع پواسون با هم برابرند.

$$p(x = k) = \frac{e^{-\lambda}\lambda^{k}}{k!}$$

تقریب پواسون برای توزیع دوجمله ای

وقتی تعداد آزمایش‌ها بزرگ و احتمال موفقیت کوچک باشد، توزیع دوجمله‌ای را می‌توان با توزیع پواسون با پارامتر λ=np تقریب زد.

n >=20

p <= 0.05

قضیه چبی شف Chebyshev

حداقل چند درصد از داده ها در یک توزیع در چه فاصله ی مشخص، حول میانگین هستند:

- وقتی توزیع داده‌ها مشخص نیست
- برای حداقل تخمین از درصد داده‌ها در دامنه‌ای مشخص

- برای تحلیل پراکندگی بدون فرض نرمال بودن

یعنی بدون توجه به اینکه داده‌ها چه توزیعی دارند، همیشه میزان زیادی از داده‌ها در فاصله **چند انحراف معیار** از میانگین قرار می‌گیرند:

$$(1 - \frac{1}{k^2}) * 100\% \text{ , } K > 1$$

مثال: میانگین نمره کلاسی ۷۰ و انحراف معیار ۵ است. چند درصد دانشجویان بین ۶۰ تا ۸۰ هستند؟

جواب: فاصله هر کدام از نمرات ۶۰ و ۸۰ تا میانگین برابر ۱۰ است. پس:

$$K * \sigma = 10 \Rightarrow k * 5 = 10 \Rightarrow K = 2 \Rightarrow (1 - \frac{1}{2^2}) * 100\% = 75\%$$

آزمایش تصادفی

فرآیندی است که:

1. تحت شرایط یکسان قابل تکرار است
2. نتیجه آن قطعی نیست(غیر قابل پیش بینی)
3. مجموعه تمام نتایج ممکن(فضای نمونه) از پیش مشخص است

مثال: پرتاب سکه یا تاس را در نظر بگیرید

مدل احتمال

یک توصیف ریاضی است از یک آزمایش تصادفی و دارای ۳ جز است:

1. فضای نمونه - Sample space

مجموعه تمام نتایج ممکن و متمایز یک آزمایش تصادفی که میتواند به صورت گسسته یا پیوسته باشد.

2. پیشامدها - Events

زیرمجموعه ای از فضای نمونه است

3. اندازه احتمال - Probability Measure

متغیر تصادفی

متغیر تصادفی یک تابع است که هر نتیجه(یا به عبارتی خروجی) از فضای نمونه را به یک عدد حقیقی نگاشت مینماید.

$X: S \rightarrow R$

از یک فضای نمونه یک نگاشت روی اعداد حقیقی انجام میشود مثلا پرتاب تاس را در نظر بگیرید که شامل {شیر، خط} است و وقتی نگاشت انجام میشود آن را به {۰، ۱} تبدیل میکنیم.

تمرین ها

تمرین ۱: روش استفاده از رگرسیون خطی را با یک مثال ساده توضیح دهید

تمرین ۲: فرمول محاسبه عدد تصادفی بین a و b را به شرطی که تابع ما عددی بین ۰ و ۱ بدهد پیدا کنید

تمرین ۳: برنامه ای بنویسید که نمودار هیستوگرام نمرات یک کلاس درسی را رسم کند.

تمرین ۴: محاسبه واریانس و انحراف معیار برای داده های زیر:

x= {20, 12, 8, 17, 14}

تمرین ۵: 10 تمرین از پایان 4 فصل را انجام دهید

تمرین اختیاری: با Netlogo یک شبیه ساز بسازید